

Progettazione e Validazione di un Framework di Valutazione Pedagogica per Sistemi Retrieval-Augmented Generation in Ambienti di E-Learning

Carmine Francesco Benvenuto

Relatore: Prof. Alessio Sacco — Politecnico di Torino, Corso di Laurea Magistrale in Ingegneria Informatica

Sommario

L'integrazione di modelli linguistici di grandi dimensioni (*Large Language Models*, LLM) in architetture *Retrieval-Augmented Generation* (RAG) offre straordinarie opportunità per il tutoring didattico intelligente. Tuttavia, i paradigmi valutativi attuali si concentrano esclusivamente sulla correttezza lessicale e sulla fedeltà documentale, ignorando la qualità pedagogica dell'interazione. Il presente lavoro introduce **rag_eval**, un framework software asincrono, modulare e multi-provider, e formalizza il **Pedagogical Evaluation Score (PES)**, una metrica gerarchica a tre livelli governata da *faithfulness*, *safety gating*, classificazione neurale dell'intento didattico e aggregazione a media geometrica pesata dinamico-adattiva. La validazione empirica condotta su oltre **4.500 interazioni** complessive — articolata su **2.475 campioni** di MRBench v3 (9 LLM), **2.040 turni reali** di MathDial e un caso di studio aziendale presso **Clait S.r.l.** (50 query RAG Triad e 30 scenari PES con telemetria in produzione) — dimostra la solidità statistica della metrica ($p = 0.048^*$, $\rho = +0.0588^{**}$), evidenziando una severa penalizzazione dello spoilering diretto (-27.4% , $p = 9.95 \times 10^{-27}$, $\eta^2 = 0.0959$), una *Refusal Accuracy* del 100% su scenari avversari e la piena competitività dei modelli open-weight locali (Llama 3.1 8B/405B) a tutela della sovranità e riservatezza dei dati didattici.

1 Introduzione e Motivazione

L'impiego di sistemi RAG per il tutoraggio personalizzato rappresenta una delle applicazioni più promettenti dell'intelligenza artificiale. Collegare i modelli linguistici a documenti esterni riduce sensibilmente il rischio di inventare informazioni (allucinazioni), ma fa emergere una domanda fondamentale: **come possiamo misurare se un assistente virtuale è davvero efficace nell'insegnare?**

Le metriche tradizionali del settore (come BLEU, ROUGE o BERTScore) si limitano a verificare quanto le parole generate somiglino a una risposta modello. Al contempo, i criteri standard usati per valutare i sistemi RAG (la cosiddetta *RAG Triad*: fedeltà alle fonti, pertinenza della risposta e accuratezza del recupero) controllano se il contenuto è corretto, ma ignorano la dimensione pedagogica. In ambito educativo, un tutor che fornisca immediatamente la soluzione esatta azzerava lo sforzo cognitivo dello studente (*productive struggle*), violando il principio dello *scaffolding* (Wood et al., 1976), ovvero il sostegno graduale che guida l'allievo verso una comprensione autonoma nella sua Zona di Sviluppo Prossimale (Vygotskij, 1978).

Questo lavoro di tesi affronta il problema proponendo tre contributi complementari:

1. **Il framework rag_eval**: una piattaforma software open-source e modulare, pensata per testare pipeline RAG educative e generali, con supporto completo sia ad API commerciali che a modelli aperti eseguiti localmente;
2. **La metrica PES (*Pedagogical Evaluation Score*)**: un indice di valutazione a tre livelli che blocca le risposte non supportate dai documenti, riconosce l'intento del dialogo e applica una media geometrica per penalizzare chi svela subito la soluzione (spoiler);
3. **La validazione sperimentale su larga scala**: una campagna di test su oltre **4.500 interazioni** (2.475 quesiti di MRBench v3, 2.040 dialoghi reali di MathDial e 80 casi applicativi presso l'azienda **Clait S.r.l.**), con esecuzione locale riproducibile e telemetria continua in produzione.

2 Architettura del Framework rag_eval

Il framework **rag_eval** è ingegnerizzato come una piattaforma software modulare, asincrona ed estendibile per la valutazione multi-paradigma di sistemi RAG. Il cuore del sistema adotta il *Registry & Strategy Pattern*, gestendo l'auto-discovery di 15 metriche eterogenee (10 convenzionali tra LLM-as-a-judge, lessicali e dense, e 5 pedagogiche specializzate) basate sul contratto comune **BaseMetric** e validate runtime tramite **Pydantic v2**. L'accesso ai modelli linguistici è mediato da una *Multi-Provider LLM Facade* (**LLMClient**) per API commerciali (OpenAI, Anthropic, Google) e motori di inferenza locale (*Ollama*, *vLLM*) a tutela della privacy (GDPR), con caching deterministico SHA-256 su disco, retry esponenziale e tracciamento dei consumi di token.

La pipeline fa capo all’orchestratore asincrono **Evaluator** (`asyncio.Semaphore`) con checkpointing incrementale *crash-safe*. L’ecosistema include chunking semantico su similarità dal centroide, generatore sintetico di tuple QA con distrattori, 8 adattatori per benchmark standard (HotpotQA, SQuAD 2.0, Natural Questions, TriviaQA, RGB, RECALL, MRBench v3, MathDial), callback per catene LangChain LCEL e un sistema di reporting quadruplo: console Rich, esportazioni tabulari (JSON, CSV) e dashboard HTML interattive completamente offline.

3 Formalizzazione della Metrica PES

Il PES modella la qualità pedagogica mediante una pipeline gerarchica a tre livelli operativi coordinati:

3.1 Livello 0 – Faithfulness Safety Gate

La risposta del tutor y viene scomposta in claim atomici $\mathcal{C}(y) = \{c_1, \dots, c_m\}$ e verificata rispetto ai contesti documentali $\mathcal{Z}$. Fissata una soglia $\tau \in [0, 1]$ (calibrata a $\tau = 0.25$ per contesti tutoriali complessi):

$$\text{PES}(y) = 0.0 \quad \text{se Faithfulness}(y, \mathcal{Z}) < \tau \quad (1)$$

Questo vincolo stabilisce che un intervento contenente allucinazioni o errori concettuali è intrinsecamente dannoso e privo di valore didattico, interrompendo immediatamente il calcolo (*short-circuit non compensativo*).

3.2 Livello 1 – Pedagogical State Intent Classifier

Superato il gate, un LLM-judge determina l’intento didattico contingente del turno $\mathcal{S} \in \{\mathcal{S}_A, \mathcal{S}_B, \mathcal{S}_C\}$, associandovi un vettore di pesi dinamici $\mathbf{w}(\mathcal{S}) = [w_1(\mathcal{S}), w_2(\mathcal{S}), w_3(\mathcal{S})]$:

- **Stato $\mathcal{S}_A$ (*Concept Teaching*)**: introduzione ed elaborazione concettuale $\implies \mathbf{w}(\mathcal{S}_A) = [0.35, 0.35, 0.30]$;
- **Stato $\mathcal{S}_B$ (*Error Remediation*)**: correzione di errori dell’allievo $\implies \mathbf{w}(\mathcal{S}_B) = [0.00, 0.30, 0.70]$;
- **Stato $\mathcal{S}_C$ (*Socratic Assessment*)**: domande maieutiche e verifica $\implies \mathbf{w}(\mathcal{S}_C) = [0.00, 0.25, 0.75]$.

Motivazione pedagogica: negli Stati $\mathcal{S}_B$ e $\mathcal{S}_C$ l’uptake conversazionale (M_1) viene deliberatamente azzerato poiché incorporare o espandere le premesse errate dello studente rischia di convalidare la misconcezione (*paradosso dell’uptake*), mentre lo scaffolding maieutico (M_3) assume peso dominante (70–75%).

3.3 Livello 2 – Sotto-Metriche Funzionali Parallele

- **M_1 – Uptake Conversazionale & Contestuale**: calcolato tramite cross-encoder NLI multilingue (`mDeBERTa-v3-base-mnli-xnli`) per stimare la probabilità di continuazione dialettica coerente con l’input dell’allievo;
- **M_2 – Adattamento Linguistico**: combinazione convessa ($0.4 \cdot S_{\text{read}} + 0.3 \cdot S_{\text{tent}} + 0.3 \cdot S_{\text{crit}}$) di leggibilità Flesch FRE normalizzata, densità socratica (lemmatizzazione multilingue con `simplemma` su lessico esplorativo) e critica costruttiva (sentiment neurale `nlptown` con bonus per connettivi avversativi);
- **M_3 – No Immediate Disclosure (NID) & Helpfulness**: combinazione bilanciata ($0.5 \cdot S_{\text{NID}} + 0.5 \cdot S_{\text{help}}$) tra il grado di non-rivelazione su scala continua $[0.0, 1.0]$ (0.0 = spoiler, 0.33 = leakage, 0.67 = hints, 1.0 = scaffolding) e l’utilità didattica percepita (scala 1–5 di Tack & Piech normalizzata).

3.4 Livello 3 – Aggregazione a Media Geometrica Pesata

L’unificazione analitica avviene tramite media geometrica pesata normalizzata con regolarizzazione $\epsilon = 10^{-6}$:

$$\text{PES}(y, q, \mathcal{Z}) = \begin{cases} 0.0 & \text{se Faithfulness}(y, \mathcal{Z}) < \tau \\ \exp\left(\frac{\sum_{i=1}^3 w_i(\mathcal{S}) \cdot \ln(\max(M_i, \epsilon))}{\sum_{i=1}^3 w_i(\mathcal{S})}\right) & \text{se Faithfulness}(y, \mathcal{Z}) \geq \tau \end{cases} \quad (2)$$

La formulazione geometrica garantisce la *non-compensatorietà*: se il tutor rivela subito la soluzione ($M_3 \rightarrow 0$), il PES collassa verso zero indipendentemente dall’eleganza stilistica (M_2), impedendo compensazioni scorrette.

4 Validazione Sperimentale e Risultati

La validazione del framework `rag_eval` e della metrica PES è stata condotta integrando due benchmark accademici su larga scala e un collaudo operativo sul campo, con inferenza locale riproducibile (Ollama, Llama 3.1 8B) a garanzia della totale riservatezza dei dati (GDPR).

1. Accordo con il giudizio umano su MRBench v3 ($N = 2.475$). Il primo banco di prova ha analizzato 2.475 risposte di tutoraggio matematico valutate da docenti e generate da 9 sistemi (tra cui GPT-4, Gemini 1.5 Pro, Llama 3.1 e tutor umani). Il PES segue fedelmente il consenso degli esperti: i punteggi medi calano con regolarità dalle risposte ottime a quelle insufficienti (0.525 per «Yes», 0.510 per «To some extent» e 0.503 per «No», $p = 0.048$). L'uso dei pesi adattivi aumenta del 30% l'allineamento con gli esperti rispetto a pesi uniformi e amplia del 28.2% la separazione Yes-No; inoltre, nel decile con il PES più alto, ben il 64% delle risposte appartiene alla classe ottimale (rapporto Yes/No di 3.16x). Emerge qui il paradosso della «maledizione della conoscenza»: i docenti umani esperti si fermano solo all'ottavo posto (0.501), poiché la loro padronanza della materia li spinge a fornire risposte dirette e concise, penalizzate dal PES che premia invece la maieutica; al contrario, LLM ad alta capacità come Gemini 1.5 Pro (0.541) e Llama 3.1 405B (0.535) eccellono nella spiegazione graduale.

2. Scaffolding contro spoiling su MathDial ($N = 2.040$). Sul corpus MathDial (2.040 turni reali annotati per mosse didattiche), il framework dimostra la capacità di distinguere la guida attiva dalla semplice rivelazione della risposta. Chi fornisce subito la soluzione (**telling**) subisce una penalizzazione del -27.4% rispetto alle strategie di scaffolding maieutico (**probing** e **focus**), con significatività categorica ($p = 9.95 \times 10^{-27}$, ANOVA $F = 71.98$, $\eta^2 = 0.0959$, effetto 56 volte superiore a MRBench grazie al setting multi-turno). La metrica premia allo stesso modo sia domande aperte che indizi mirati ($p = 0.169$), bocciando solo la passività risolutiva; con modelli di frontiera (GPT-5 Nano), la penalizzazione dello spoiling sale al -30.5% ($\eta^2 = 0.1244$). Questo studio evidenzia inoltre il «paradosso della maieutica»: un filtro rigido di fedeltà boccerebbe a torto oltre il 60% delle domande socratiche (prive di fatti documentali espliciti), motivando la scelta di modulare il gate sui turni esplorativi.

3. Collaudo operativo aziendale presso Clait S.r.l. ($N = 80$). La sperimentazione sul campo ha valutato un assistente RAG per l'e-learning aziendale su 80 casi operativi. L'audit della *RAG Triad* (50 quesiti) attesta ottima fedeltà (0.89) e pertinenza (0.95) sui percorsi interni (con supporto bilingue IT/EN) e una **Refusal Accuracy del 100%** su 17 test avversari o fuori perimetro, bloccando ogni allucinazione normativa. La valutazione con il PES (30 scenari didattici) conferma un solido radicamento nei testi ($M_1 = 0.671$, 90% di gate pass), ma individua due limiti tipici dei modelli attuali: una forte rigidità stilistica (Flesch FRE 14.06, tono da manuale tecnico) e la tendenza a fornire monologhi enciclopedici anche in compiti socratici ($M_3 = 0.427$), offrendo indicazioni preziose per il prompt engineering. Infine, la telemetria continua in produzione (Prometheus/Grafana) certifica la piena sostenibilità del sistema: latenza media di **4.96 secondi** e costo di appena **\$0.00040 per query** (circa **€0,37 ogni 1.000 interrogazioni**).

5 Conclusioni e Sviluppi Futuri

Il lavoro svolto dimostra che è possibile quantificare con rigore scientifico la qualità pedagogica nei sistemi RAG, colmando il divario tra la correttezza documentale e l'effettivo valore formativo dell'interazione. Attraverso il framework `rag_eval` e l'indice PES, la valutazione automatica impara a premiare la maieutica dello scaffolding e a penalizzare lo spoiling passivo. Un riscontro fondamentale sul piano pratico ed etico risiede nella piena competitività dei modelli open-weight compatti eseguiti in locale (come Llama 3.1 8B), capaci di eguagliare le prestazioni di costosi LLM proprietari: ciò comprova la piena fattibilità di assistenti didattici privati, sostenibili a livello economico e conformi ai requisiti di sovranità e privacy del GDPR.

Le prospettive future si articolano su tre direttrici principali: in primo luogo, l'estensione al RAG multimodale, per valutare spiegazioni comprensive di formule matematiche, grafici e lavagne digitali; in secondo luogo, la stima adattiva in tempo reale del carico cognitivo e della Zona di Sviluppo Prossimale dell'allievo; infine, l'impiego del PES come funzione di ricompensa (*reward model*) per l'addestramento e l'allineamento diretto di nuovi modelli tutoriali tramite tecniche di *Reinforcement Learning from AI Feedback* (RLAIF) e *Direct Preference Optimization* (DPO).